Mestrado em Ciência de Dados

UC: Fundamentos de programação

Docentes: João Moreira e Tiago Prata

Ano Letivo 2025/2026

Real Estate Lisboa

Grupo nº 2:

André Marques, nº 136447, (30%)

Fernando Rocha, nº 134110, (37%)

Frederico Ferreira, nº135644, (33%)

Índice

1. Domínio
2. Fonte de dados
3. Aquisição dos Dados
4. Processamento dos Dados
5. Criação do Modelo Preditivo
6. Visualização dos Dados
7. Conclusão
8. Anexos

Real Estate Lisboa

Domínio

Este projeto centra-se no mercado imobiliário residencial português, com enfoque no distrito de Lisboa. A escolha justifica-se pela relevância económica de Lisboa, que concentra a maior densidade populacional do país e os valores de transação imobiliária mais elevados.

O objetivo central é compreender os principais fatores que influenciam o preço de venda das habitações destinadas à residência permanente, nomeadamente apartamentos e *duplex*. Excluímos tipologias não comparáveis como vivendas, terrenos, lojas ou espaços industriais, assegurando maior consistência na modelação preditiva. As variáveis utilizadas refletem a estrutura típica de anúncios imobiliários: preço, área, número de divisões, entre outros atributos que permitem identificar padrões relevantes para a estimativa do preço de venda.

Fonte de dados

A base de dados utilizada neste trabalho é o "Portuguese Real Estate Dataset" de 2024, disponível publicamente no *Kaggle* e compilado por Gonçalo Baião. O conjunto contém mais de 120 mil anúncios de imóveis para venda em Portugal, o que o torna apropriado tanto para análises exploratórias como para a criação de modelos preditivos.

O *dataset* inclui a informação habitual presente em anúncios imobiliários: preço do imóvel, a área total, o número de divisões, o número de casas de banho, o tipo de propriedade e a sua localização (distrito e município), como se pode observar no Anexo 1. Estes elementos permitem caracterizar cada imóvel com algum detalhe e, ao mesmo tempo, adaptar o conjunto de dados ao objetivo do projeto. No nosso caso, aplicamos um filtro para manter apenas os imóveis do distrito de Lisboa e limitar a análise às tipologias *Apartment* e *Duplex*, assegurando que trabalhamos apenas com propriedades destinadas à habitação urbana.

O ficheiro é disponibilizado em formato CSV, o que facilita a importação e o tratamento dos dados através de bibliotecas como o "pandas".

Aquisição dos Dados

Os dados foram obtidos diretamente do *Kaggle* através da biblioteca *kagglehub*, garantindo a versão mais atual disponível na plataforma. O *dataset* foi carregado para um *DataFrame* com pandas, ajustando manualmente os tipos de algumas colunas com inconsistências para garantir uma importação correta.

Processamento dos Dados

Selecionámos um subconjunto de atributos pela sua relação teórica com o preço e pela prevalência de valores não nulos: "Price", "District", "City", “Town”, "TotalArea", "Type", "HasParking", "ConstructionYear", "HasElevator", "TotalRooms" e "NumberOfBathrooms".

Filtrámos os dados para manter apenas registos do distrito de Lisboa. Esta decisão metodológica baseou-se no facto de o mercado imobiliário português não ser homogéneo: o preço de um apartamento em Lisboa e num distrito do interior obedece a lógicas completamente diferentes. Embora o próprio mercado de Lisboa não seja internamente homogéneo, delimitar a análise reduz a variabilidade exógena e permite ao modelo captar os padrões específicos deste mercado, resultando em previsões mais precisas.

Corrigimos as colunas *HasParking* e *HasElevator*, convertendo o texto "True" para tipo booleano, pois o *dataset* original armazenava estes valores como *strings* e os modelos *scikit-learn* exigem entradas numéricas ou lógicas.

Limitámos a análise aos tipos "Apartment" e "Duplex", excluindo categorias com lógicas de valorização distintas (lojas, terrenos, vivendas) que introduziriam ruído no modelo.

Criámos a coluna "Age" subtraindo *ConstructionYear* de 2024, estabelecendo uma relação mais direta e interpretável com o preço: um aumento na idade do imóvel está associado a uma diminuição do preço.

De seguida, excluímos linhas onde *Price* era nulo, pois num modelo de aprendizagem supervisionada é impossível treinar sem o valor real do preço. Após análise dos percentis da área total, definimos o limite superior em 10 000 m² para manter a integridade do conjunto de dados. Aplicámos assim filtros para manter registos onde *TotalArea* estava entre 20 e 10 000 m² e *NumberOfBathrooms* era maior ou igual a zero, removendo dados manifestamente incorretos. O exemplo do *dataset* limpo pode ser consultado no Anexo 2.

Criação do Modelo Preditivo

O objetivo do modelo preditivo é estimar o valor de venda dos imóveis residenciais no distrito de Lisboa, configurando-se como um problema de regressão supervisionada. Definimos *Price* como variável-alvo e categorizámos os atributos em numéricos (*TotalArea*, *Age*, *TotalRooms*, *NumberOfBathrooms*), categóricos (*City*, *Town*, *Type*) e booleanos (*HasParking*, *HasElevator*).

A modelação foi implementada através de um pipeline *scikit-learn* que encapsula todas as etapas de pré-processamento, garantindo que os dados de treino e teste sejam transformados de forma idêntica. Para atributos numéricos, utilizámos *SimpleImputer* com mediana; para categóricos, *SimpleImputer* com moda seguido de *OneHotEncoder*; para booleanos, mantivemos os valores originais.

Como estimador, selecionámos o *RandomForestRegressor* pela sua capacidade preditiva, robustez a *outliers* e habilidade de capturar relações não-lineares complexas. O *dataset* foi dividido em conjuntos de treino (80%) e teste (20%). O modelo foi treinado no conjunto de treino e o desempenho avaliado no conjunto de teste para aferir a capacidade de generalização.

Para avaliação, utilizámos R^2 (Coeficiente de Determinação), MAE (Erro Médio Absoluto), RMSE (Raiz do Erro Quadrático Médio) e MAPE (Erro Percentual Médio Absoluto). O modelo alcançou um R^2 de 0.89, MAE de 70 818.69 €, RMSE de 153 036.23 € e MAPE de 15.13%, como se pode observar no Anexo 3.

Os resultados mostram um modelo consistente, com bom nível de explicação da variabilidade do preço e valores de erro dentro do expectável para o mercado de Lisboa.

Visualização dos Dados

Para a análise exploratória do *dataset*, foram geradas cinco visualizações através da biblioteca *matplotlib*, com o objetivo de compreender a estrutura dos dados e as relações entre as variáveis.

O gráfico de barras (Anexo 4) compara o preço médio por tipo de imóvel. Este tipo de gráfico é ideal para comparações entre categorias discretas, pois permite perceção visual imediata através do alinhamento e comprimento das barras. A análise revela que os *duplex* apresentam valor médio mais elevado que os apartamentos.

O gráfico de dispersão (Anexo 5) examina a relação entre área total e preço. Este tipo de gráfico é a ferramenta padrão para visualizar correlações entre duas variáveis contínuas, permitindo identificar padrões e relações. A escala logarítmica em ambos os eixos (log-log) normaliza as distribuições assimétricas de ambas as variáveis, revelando uma relação linear entre o logaritmo da área e o logaritmo do preço.

O histograma (Anexo 6) analisa a distribuição da variável-alvo isoladamente. Este tipo de visualização é essencial para compreender a forma da distribuição de variáveis numéricas. A escala logarítmica no eixo X compensa a forte assimetria dos dados de preço, permitindo observar toda a gama de valores sem que *outliers* distorçam a visualização.

O *boxplot* (Anexo 7) compara a distribuição de preços entre cidades. Este tipo de gráfico é superior a gráficos de barras simples pois apresenta um resumo estatístico completo (mediana, quartis, *outliers*) para cada categoria, permitindo comparações de distribuições e não apenas de médias. A escala logarítmica no eixo Y torna as distribuições comparáveis entre cidades com níveis de preço muito distintos.

Por fim, a matriz de correlação (Anexo 8) analisa as relações lineares entre variáveis numéricas. Este tipo de visualização é fundamental para identificar rapidamente quais atributos estão mais fortemente associados à variável-alvo. A análise revela que o número de casas de banho apresenta a correlação mais forte com o preço, seguida da área total e do número total de divisões. A

idade do imóvel mostra uma correlação negativa moderada, confirmando que imóveis mais antigos tendem a ter preços mais baixos.

Conclusão

Este projeto permitiu criar um modelo preditivo para estimar preços de imóveis residenciais no distrito de Lisboa, obtendo um desempenho consistente, atingindo um nível de desempenho que combina uma boa capacidade de explicação da variação dos preços com um erro médio relativamente baixo, num mercado particularmente variado e difícil de modelar. Um dos aspetos que considerámos mais interessantes foi a exploração das diferentes visualizações de dados, que ajudaram a perceber melhor os padrões e as especificidades do mercado imobiliário urbano de Lisboa.

A maior dificuldade surgiu na gestão de outliers e de valores incoerentes presentes no dataset, sobretudo na definição de limites razoáveis para a área total. Este processo exigiu várias iterações e uma análise cuidada das distribuições, de forma a garantir que o conjunto final de dados fosse consistente e que o modelo produzisse resultados fiáveis.

Anexos

Anexo 1- Exemplo de uma observação do dataset original

```
df.head()
✓ [119] 34ms
```

	Price	District	City	Town	Type	EnergyCertificate	GrossArea	TotalArea	Parking	HasParking	...	Elevator	ElectricCarsCharging	TotalRooms	Number
0	780000.0	Vila Real	Valpaços	Carrazedo de Montenegro e Curros	Farm	NC	200.0	552450.0	0.0	False	...	False	NaN	NaN	
1	223000.0	Faro	São Brás de Alportel	São Brás de Alportel	Apartment	A+	NaN	81.0	1.0	True	...	True	NaN	2.0	
2	228000.0	Faro	São Brás de Alportel	São Brás de Alportel	Apartment	A+	NaN	108.0	1.0	True	...	True	NaN	2.0	
3	250000.0	Faro	São Brás de Alportel	São Brás de Alportel	Apartment	A+	NaN	114.0	1.0	True	...	True	NaN	2.0	
4	250000.0	Faro	São Brás de Alportel	São Brás de Alportel	Apartment	A+	NaN	114.0	1.0	True	...	True	NaN	2.0	

5 rows × 25 columns

```
df.head()
✓ [119] 34ms
```

ing	HasParking	...	Elevator	ElectricCarsCharging	TotalRooms	NumberOfBedrooms	NumberOfWC	ConservationStatus	LivingArea	LotSize	BuiltArea	NumberOfBathrooms
0.0	False	...	False	NaN	NaN	NaN	NaN	NaN	120.0	NaN	NaN	0.0
1.0	True	...	True	NaN	2.0	NaN	NaN	NaN	81.0	NaN	NaN	2.0
1.0	True	...	True	NaN	2.0	NaN	NaN	NaN	108.0	NaN	NaN	2.0
1.0	True	...	True	NaN	2.0	NaN	NaN	NaN	114.0	NaN	NaN	0.0
1.0	True	...	True	NaN	2.0	NaN	NaN	NaN	114.0	NaN	NaN	2.0

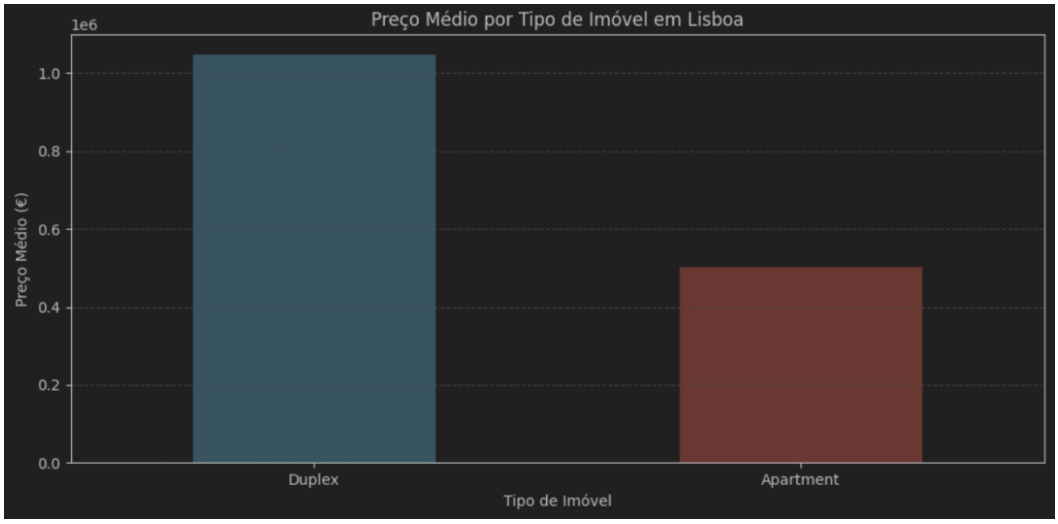
Anexo 2 - Exemplo de uma observação do dataset após o processamento dos dados

	Price	City	Town	Type	TotalArea	HasParking	Elevator	TotalRooms	NumberOfBathrooms	Age
757	200000.0	Sintra	Algueirão-Mem Martins	Apartment	79.0	True	True	2.0	1.0	24.0
1619	595000.0	Lisboa	Misericórdia	Apartment	110.0	False	False	4.0	2.0	87.0
1640	315000.0	Lisboa	Ajuda	Apartment	68.0	False	True	2.0	1.0	61.0
1682	100000.0	Azambuja	Azambuja	Apartment	208.0	False	False	2.0	1.0	46.0
2202	310000.0	Lisboa	Ajuda	Apartment	68.0	False	True	2.0	1.0	61.0

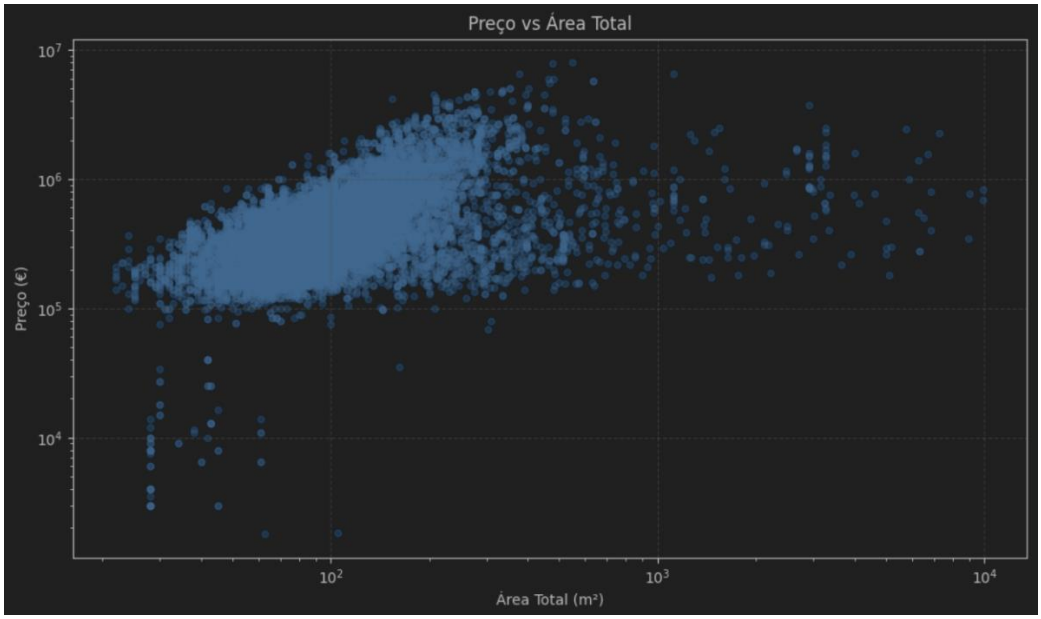
Anexo 3 - Métricas de desempenho do modelo preditivo

R^2: 0.89
MAE: 70,818.69 €
RMSE: 153,036.23 €
MAPE: 15.13%

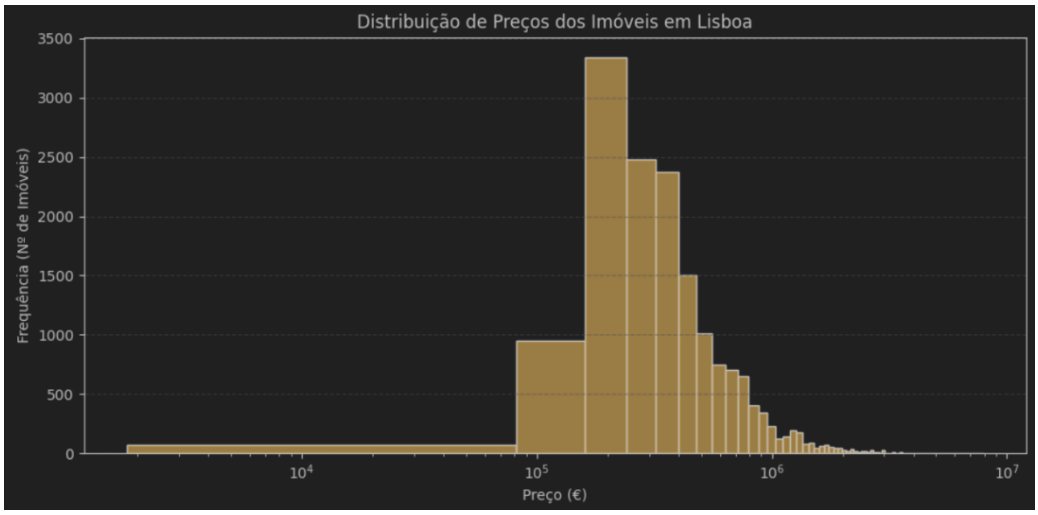
Anexo 4 - Preço médio por tipo de imóvel urbano no distrito de Lisboa



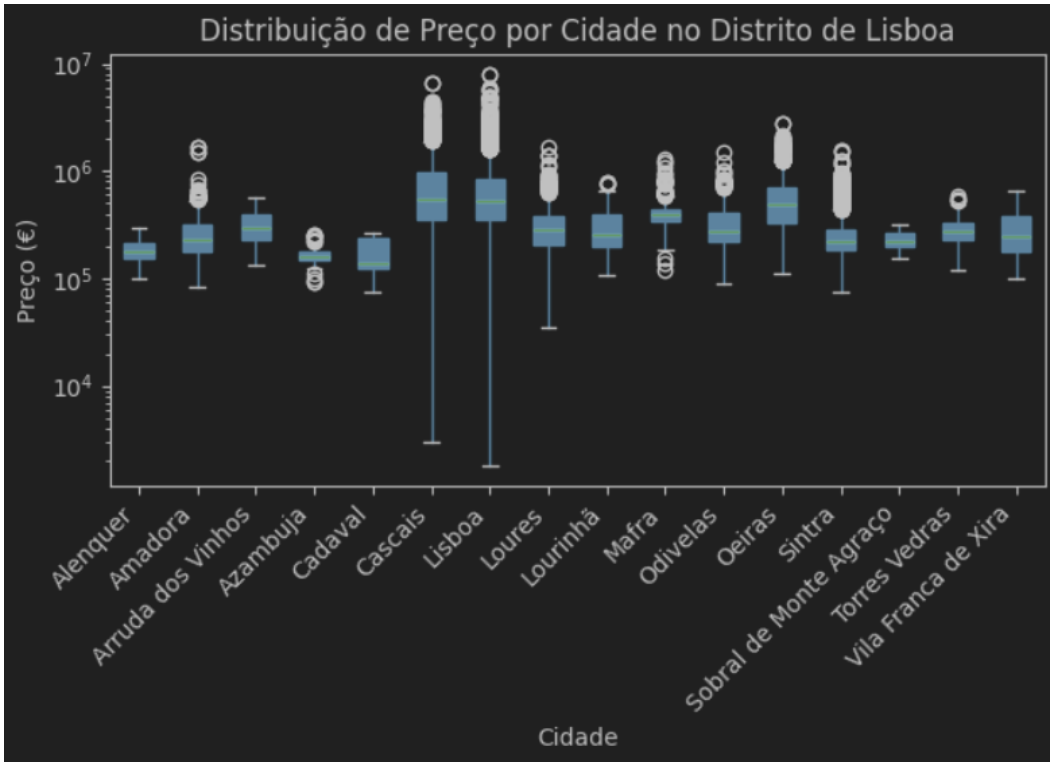
Anexo 5 - Relação entre a área total e o preço dos imóveis (escala log. no eixo Y)



Anexo 6 - Distribuição dos preços dos imóveis urbanos no distrito de Lisboa (escala log. no eixo X)



Anexo 7 - Distribuição dos preços por cidade no distrito de Lisboa (boxplot com escala log.)



Anexo 8 - Matriz de correlação entre variáveis numéricas

